


# Réseaux Bayésiens

## Définition - Inférence

Philippe Leray


`Philippe.Leray@insa-rouen.fr`

INSA Rouen – Département ASI – Laboratoire PSI (FRE CNRS 2645)



# Introduction

- Modèle graphique (MG) = mariage entre la théorie des graphes et la théorie des probabilités
  - graphe d'états
  - probabilités de transition



- De nombreux modèles utilisés en Machine Learning peuvent être vus comme des cas précis de MG
  - Modèles de Markov Cachés (HMM)
  - Réseaux Bayésiens (RB)
  - ...

# Plan

- Définition
  - Algorithmes d'inférence
    - Bucket Elimination
    - Message Passing (Pearl)
    - Junction Tree (Jensen)
  - Applications et Offre logicielle
- 
- Apprentissage
    - des paramètres
    - de la structure
  - Modèles étendus
    - variables continues : modèles conditionnels gaussiens
    - problèmes temporels : modèles dynamiques
    - théorie de la décision : diagrammes d'influence

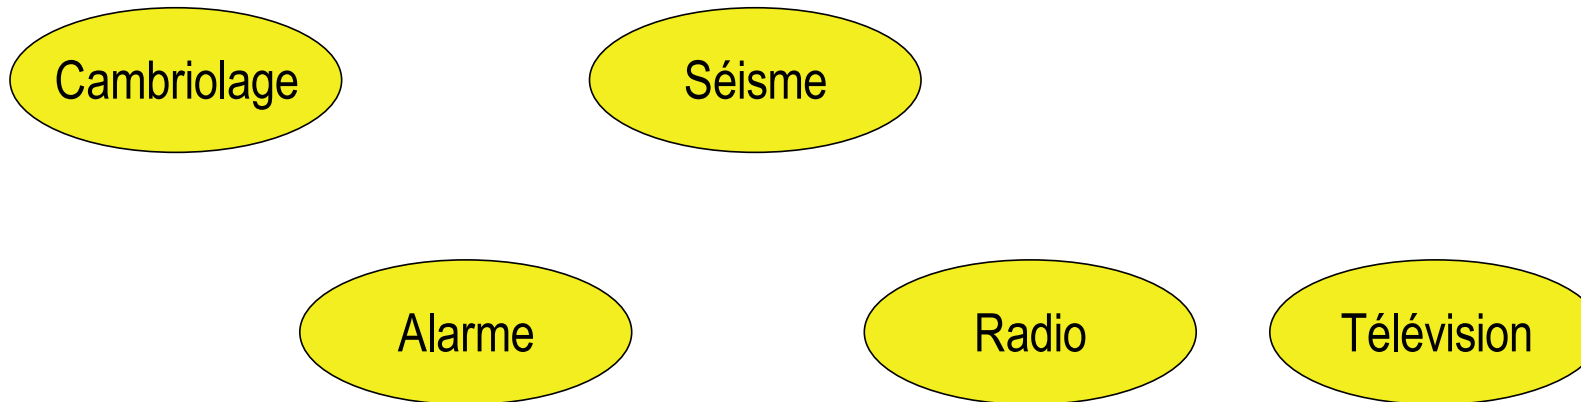


# Origine

- Inspiration des systèmes experts :
  - règles :
    - si soleil=VRAI et arrosage=FAUX, alors sol=sec
  - comment rajouter des informations probabilistes ?
    - $P(\text{soleil}) = 0.3$        $P(\text{arrosage}) = 0.5$        $P(\text{sec}) = ?$
  - comment inverser l'inférence d'un SE ?
    - $P(\text{sec}) = 0.9$        $P(\text{arrosage}) = 0.5$        $P(\text{soleil})?$
- (Pearl 1988) Raisonnement probabiliste
- De nombreuses appellations :
  - SE bayésien, SE probabiliste, réseau de croyance, réseau causal
  - belief network, bayesian network, probabilistic independence networks

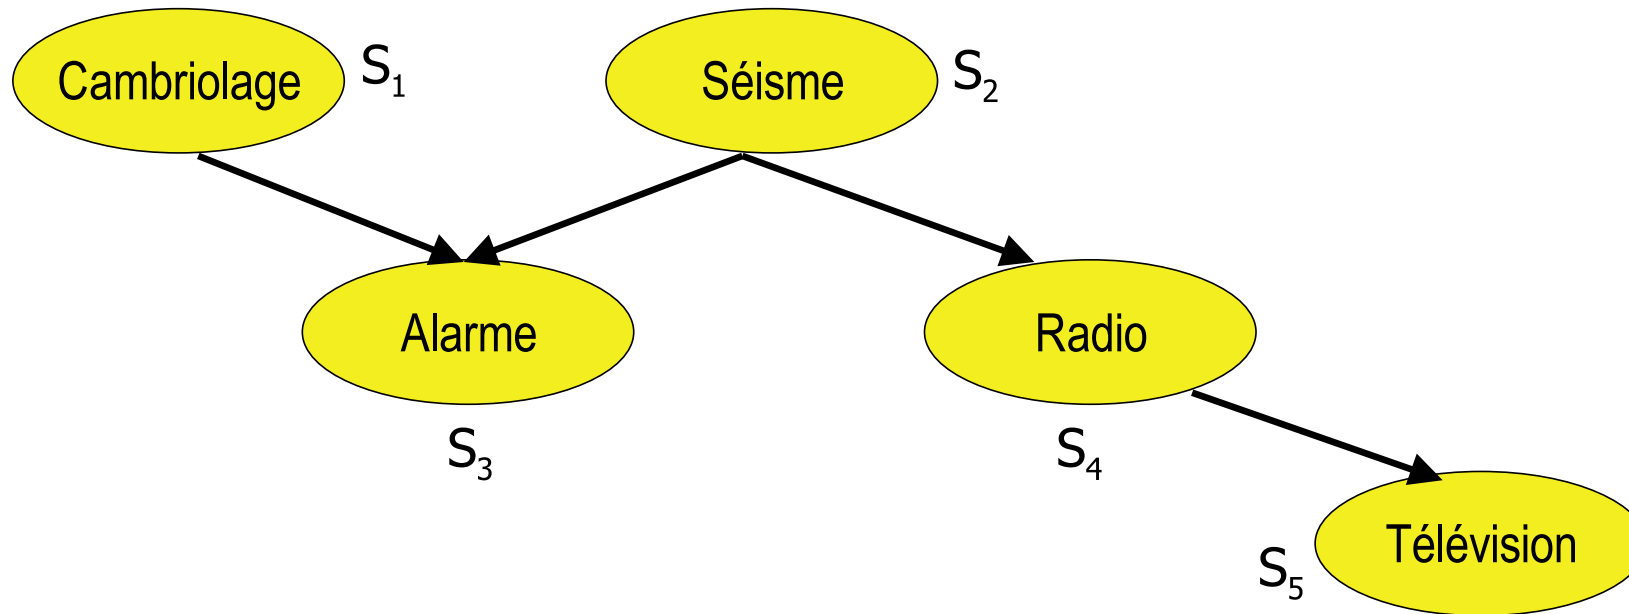
# Réseau Bayésien

- Réseau bayésien =
  - description qualitative des dépendances entre des variables (graphe causal)
  - description quantitative de ces dépendances
- Exemple



# Exemple

- Dépendance entre les variables (graphe)
  - DAG = Directed Acyclic Graph
  - Numérotation des variables dans l'ordre topologique




# Exemple

## ■ Description quantitative des dépendances (probabilités conditionnelles)

$P(\text{Cambriolage}) = [0.001 \ 0.999]$

$P(\text{Séisme}) = [0.0001 \ 0.9999]$



$P(\text{Radio}|\text{Séisme})$

	Séisme =	
	O	N
Radio=O	0.99	0.01
Radio=N	0.01	0.99

$P(\text{Télévision}|\text{Radio})$

	Radio =	
	O	N
Télé=O	0.99	0.50
Télé=N	0.01	0.50

$P(\text{Alarme}|\text{Cambriolage}, \text{Séisme})$


	Cambriolage, Séisme =			
	O,O	O,N	N,O	N,N
Alarme=O	0.75	0.10	0.99	0.10
Alarme=N	0.25	0.90	0.01	0.90

# Indépendance Conditionnelle

- Indépendance conditionnelle :
  - $A$  et  $B$  sont indépendants conditionnellement à  $C$  ssi :
    - lorsque l'état de  $C$  est connu, toute connaissance sur  $B$  n'altère pas  $A$
    - $P(A|B, C) = P(A|C)$
- Les RB vont servir à représenter graphiquement les indépendances conditionnelles
- Exemple sur 3 nœuds
  - 3 types de relations possibles entre  $A$ ,  $B$  et  $C$  ...




# Indépendance Conditionnelle




- Connexion série
- $A$  et  $B$  sont dépendants
- $A$  et  $B$  sont indépendants conditionnellement à  $C$ 
  - si  $P(C)$  est connue,  
 $A$  n'intervient pas dans le calcul de  $P(B)$
  - $P(S_5|S_4, S_2) = P(S_5|S_4) = P(S_5|parents(S_5))$

# Indépendance Conditionnelle



- Connexion divergente
- $A$  et  $B$  sont dépendants
- $A$  et  $B$  sont indépendants conditionnellement à  $C$ 
  - si  $P(C)$  est connue,  
 $A$  n'intervient pas dans le calcul de  $P(B)$
  - $P(S_4|S_2, S_3) = P(S_4|S_2) = P(S_4|parents(S_4))$

# Indépendance Conditionnelle



- Connexion convergente ( $A, B, C$  est une V-structure)
- $A$  et  $B$  sont indépendants
- $A$  et  $B$  sont dépendants conditionnellement à  $C$ 
  - si  $P(C)$  est connue,  
 $P(A)$  intervient pas dans le calcul de  $P(B)$
  - $P(S_3|S_1, S_2) = P(S_3|parents(S_3))$

# Conséquence

- RB = représentation compacte de la loi jointe  $P(S)$

- Théorème de Bayes :

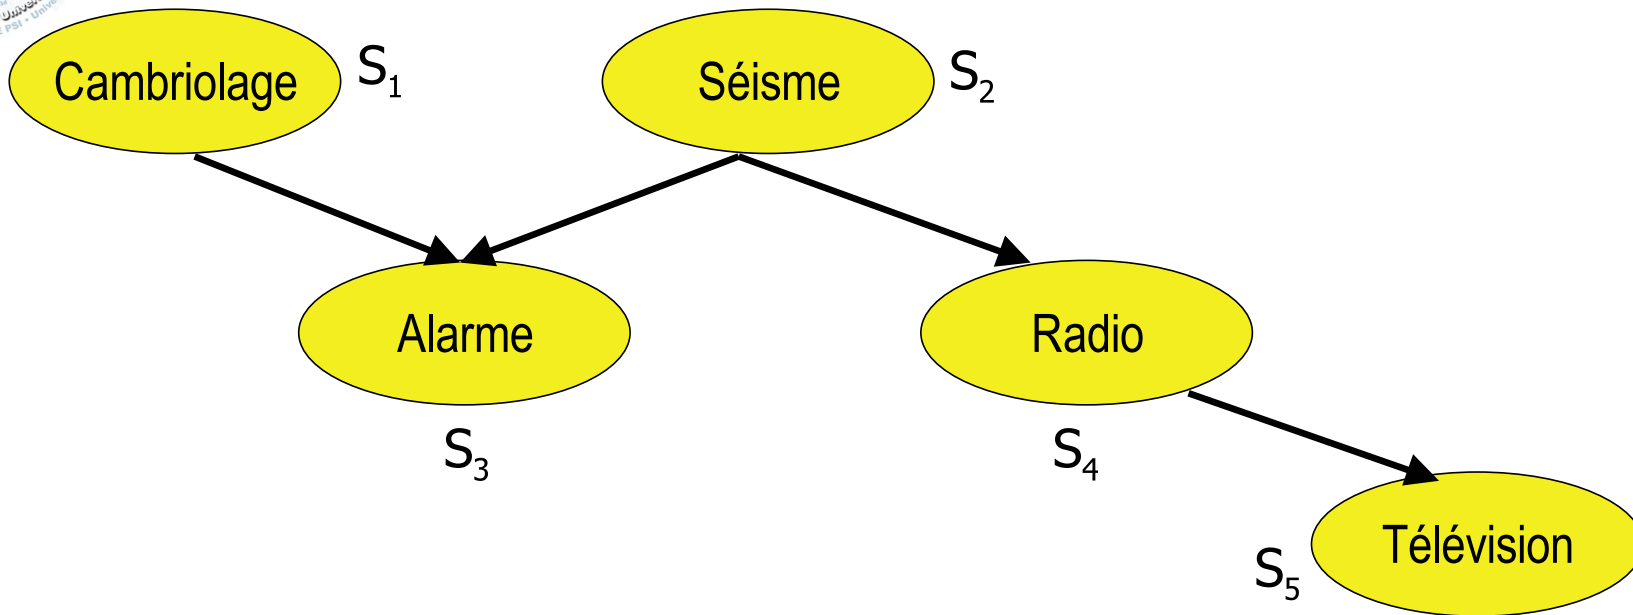
$$P(S) = P(S_1) \times P(S_2|S_1) \times P(S_3|S_1, S_2) \times \dots \times P(S_n|S_1 \dots S_{n-1})$$

- Mais dans un RB,  $P(S_i|S_1 \dots S_{i-1}) = P(S_i|\text{parents}(S_i))$   
d'où

$$P(S) = \prod_{i=1}^n P(S_i|\text{parents}(S_i))$$

- La loi jointe (globale) se décompose en un produit de lois locales

# Exemple



$$P(\text{Cambriolage}, \text{Seisme}, \text{Alarme}, \text{Radio}, \text{Tele}) =$$

$$P(S_1)P(S_2|S_1)P(S_3|S_1, S_2)P(S_4|S_1, S_2, S_3)P(S_5|S_1, S_2, S_3, S_4)$$

$$P(S_1) \quad P(S_2) \quad P(S_3|S_1, S_2) \quad P(S_4|S_2) \quad P(S_5|S_4)$$



# La d-séparation

## ■ Principe

- déterminer si 2 variables quelconques sont indépendantes conditionnellement à un ensemble de variables instantiées


## ■ Définition

- Deux variables  $A$  et  $B$  sont d-séparées si pour tous les chemins entre  $A$  et  $B$ , il existe une variable intermédiaire  $V$  différente de  $A$  et  $B$  telle que
  - la connexion est série ou divergente et  $V$  est instancié
  - la connexion est convergente et ni  $V$  ni ses descendants ne sont instanciés

- Si  $A$  et  $B$  ne sont pas d-séparés, ils sont d-connectés

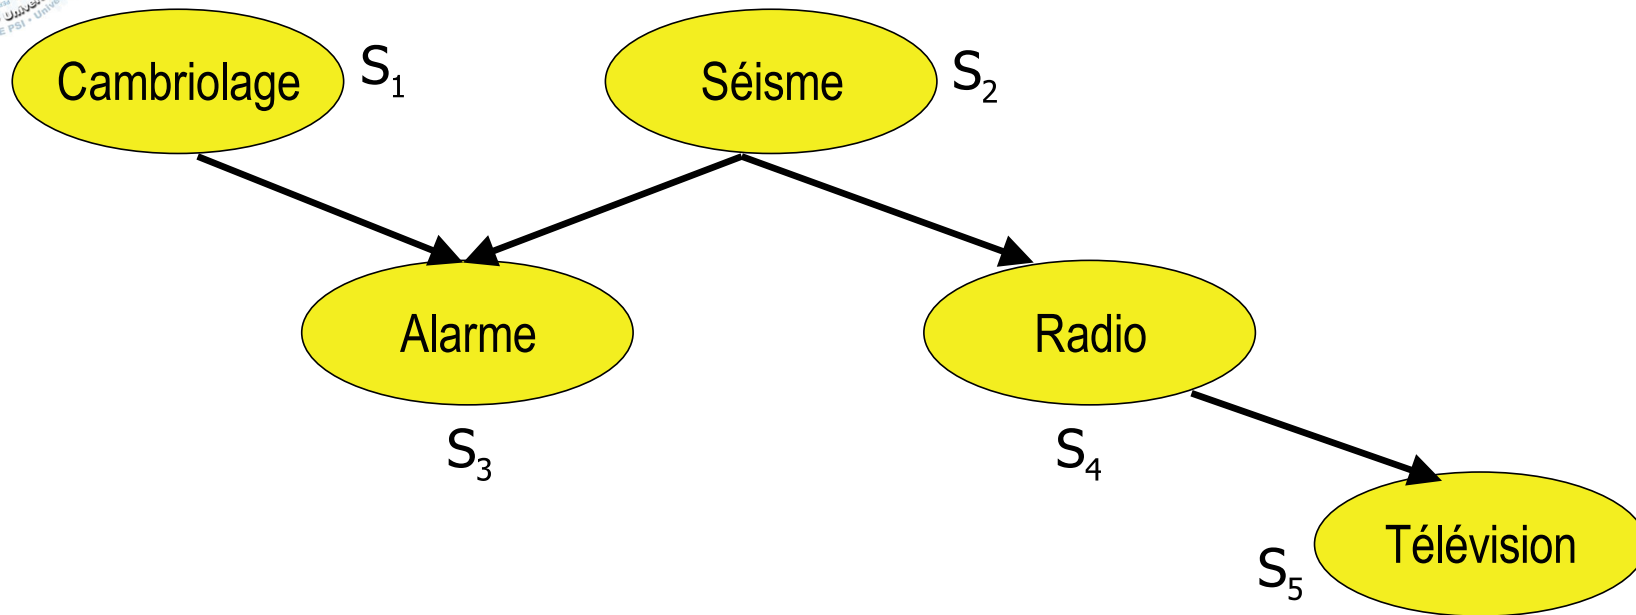


# Exemple



- exemple de d-séparation :  $S_1 \dots S_4$  ?
  - $V = S_3$  sur le chemin entre  $S_1$  et  $S_4$ .
  - la connexion est convergente en  $V$
  - $V$  n'est pas instancié
- $S_1$  et  $S_4$  sont d-séparés  
(si  $S_3$  était mesuré,  $S_1$  et  $S_4$  seraient d-connectés)

# Exemple



- autre exemple de d-séparation :  $S_2 \dots S_5$  ?
  - $V = S_4$  sur le chemin entre  $S_2$  et  $S_5$ .
  - la connexion est série en  $V$
  - $V$  n'est pas instancié
- $S_2$  et  $S_5$  sont d-connectés  
(si  $S_4$  était mesuré,  $S_2$  et  $S_5$  seraient d-séparés)



# Inférence

- Inférence = calcul de n'importe quelle  $P(S_i | S_j = x)$   
NB : l'observation  $\{S_j = x\}$  est appelée l'évidence
- A quoi sert la loi jointe  $P(S) = P(S_1, \dots, S_n)$  ?
- Rappel : marginalisation

$$P(S_i) = \sum_{s_1, s_2, \dots, s_n} P(S_1 = s_1, S_2 = s_2, \dots, S_i, \dots, S_n = s_n)$$

- d'où

$$P(S_i | S_j = x) = \frac{P(S_i, S_j = x)}{P(S_j = x)} = \frac{\sum_{\{s_k\}_{k \neq i, j}} P(S_1 = s_1, \dots, S_i, S_j = x, \dots, S_n = s_n)}{\sum_{\{s_k\}_{k \neq j}} P(S_1 = s_1, \dots, S_j = x, \dots, S_n = s_n)}$$

- Un RB décompose cette loi jointe, ce qui permet de simplifier les calculs



# Quelques algorithmes d'inférence

- Algorithmes exacts
  - Bucket Elimination
  - Message Passing (Pearl 88) pour les arbres
  - Junction Tree (Jensen 90)

Problème = explosion combinatoire de ces méthodes pour des graphes fortement connectés, etc ...  
(inférence = problème NP-complet)

- Algorithmes approchés
  - Echantillonnage : Markov Chain Monte Carlo, ...
  - Méthodes variationnelles

# Bucket Elimination

## ■ Principe

- grâce à la décomposition de la loi jointe, certaines étapes de la marginalisation de  $P(S_i, S_j = x)$  se simplifient

## ■ Exemple

- évidence  $E = \{S_4 = O\}$ , on cherche  $P(S_2|E)$

$$P(S, E) = P(S_1)P(S_2)P(S_3|S_1S_2)P(S_4 = 0|S_2)P(S_5|S_4 = O)$$

$$P(S_2, E) = \sum_{S_1, S_3, S_5} P(S, E)$$

- et si on choisit l'ordre des variables pour la marginalisation ?

# Bucket Elimination

- Commençons par  $S_5$

$$\begin{aligned} \sum_{S_5} P(S_1, S_2, S_3, S_4 = O, S_5) &= P(S_1)P(S_2)P(S_3|S_1, S_2) \dots \\ &\dots P(S_4 = O|S_2) \sum_{S_5} P(S_5|S_4 = O) \end{aligned}$$

- Cette dernière somme vaut 1 ! On a éliminé  $S_5$

$$P(S_1, S_2, S_3, S_4 = O) = P(S_1)P(S_2)P(S_3|S_1, S_2)P(S_4 = O|S_2)$$

- Au tour de  $S_1$

# Bucket Elimination

$$\sum_{S_1} P(S_1, S_2, S_3, S_4 = O) = P(S_2)P(S_4 = O|S_2) \dots$$

$$\dots \sum_{S_1} P(S_1)P(S_3|S_1, S_2)$$

- Cette dernière somme nous rend une table dépendant de  $S_2$  et  $S_3$  :  $T(S_2, S_3)$

$$P(S_2, S_3, S_4 = O) = P(S_2)P(S_4 = O|S_2)T(S_2, S_3)$$

- Idem avec  $S_3$  pour obtenir  $P(S_2, S_4 = O)$

Marginalisation = série de produits locaux de matrices et de marginalisations locales

# Message Passing (Pearl 1988)

- Chaque nœud envoie des messages à ses voisins
- L'algorithme ne marche que dans le cas des arbres
- (mais est généralisable au cas des poly-arbres)

- $E$  = ensemble de variablesinstanciées.

$$E = N_x \cup D_x$$


- 2 types de messages  $\lambda$  et  $\pi$  serviront à calculer

- $\lambda(X) \propto P(D_x|X)$

- $\pi(X) \propto P(X|N_x)$

- et ensuite on peut montrer que

$$P(X|E = e) \propto \lambda(X)\pi(X)$$



# Message Passing

- Les messages  $\lambda$ 
  - Pour chaque enfant  $Y$  de  $X$ ,

$$\lambda_Y(X = x) = \sum_y P(Y = y | X = x) \lambda(Y = y)$$

- Comment calculer  $\lambda$  en chaque nœud ?
  - Si  $X$  instancié,  $\lambda(X) = [001 \dots 0]$   
(la position du 1 correspond à la valeur donnée à  $X$ )
  - sinon
    - si  $X$  est une feuille,  $\lambda(X) = [1 \dots 1]$
    - sinon

$$\lambda(X = x) = \prod_{Y \in \text{Enf}(X)} \lambda_Y(X = x)$$

# Message Passing

- Les messages  $\pi$ 
  - Pour  $Z$  l'unique parent de  $X$ ,

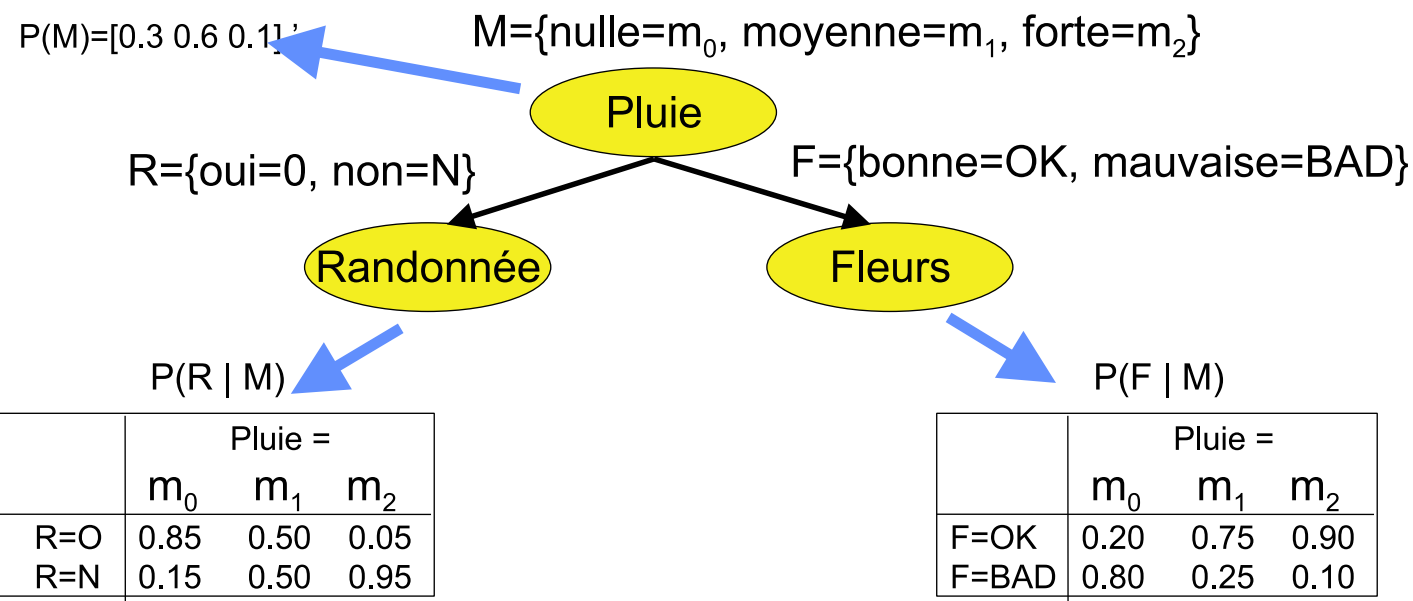
$$\pi_X(Z = z) = \pi(Z = z) \prod_{U \in \text{Enf}(Z) \setminus \{X\}} \lambda_U(Z = z)$$

- Comment calculer  $\pi$  en chaque nœud ?
  - Si  $X$  instancié,  $\lambda(X) = [001 \dots 0]$   
(la position du 1 correspond à la valeur donnée à  $X$ )
  - sinon
    - si  $X$  est la racine,  $\pi(X) = P(X)$
    - sinon

$$\pi(X = x) = \sum_z P(X = x | Z = z) \pi_X(Z = z)$$



# Exemple



■  $E = \emptyset$

$P(F) = ?$


$P(R) = ?$

$$P(F) = \sum_m P(F|M = m)P(M = m)$$

0.20	0.75	0.90	0.3
0.80	0.25	0.10	0.6
			0.1
			<b>0.6</b>
			<b>0.4</b>

0.85	0.50	0.05	0.3
0.15	0.50	0.95	0.6
			0.1
			<b>0.56</b>
			<b>0.44</b>

# Exemple



■  $E = \{M = m_2\}$

■  $\lambda(M) = \pi(M) = [0 \ 0 \ 1]$  (nœud instancié)


■  $P(M|E) \propto \lambda(M)\pi(M) = [0 \ 0 \ 1]$  (logique)

■ messages envoyés aux enfants :

■  $\pi_R(M) = \pi(M)\lambda_F(M) = [0 \ 0 \ 1]$

■  $\pi_F(M) = \pi(M)\lambda_R(M) = [0 \ 0 \ 1]$

# Exemple



■  $E = \{M = m_2\}$  suite...

■ en  $R$  :

■  $\pi(R) = P(R|M)\pi_R(M) = [0.05 \ 0.95]$

■  $\lambda(R) = [1 \ 1]$  (feuille)


■  $P(R|E) \propto \lambda(R)\pi(R) = [0.05 \ 0.95]$

	0
	0
	1

0.85	0.50	0.05	0.05
0.15	0.50	0.95	0.95

**Pluie=Forte  $\Rightarrow$  Randonnée=Non**

# Exemple



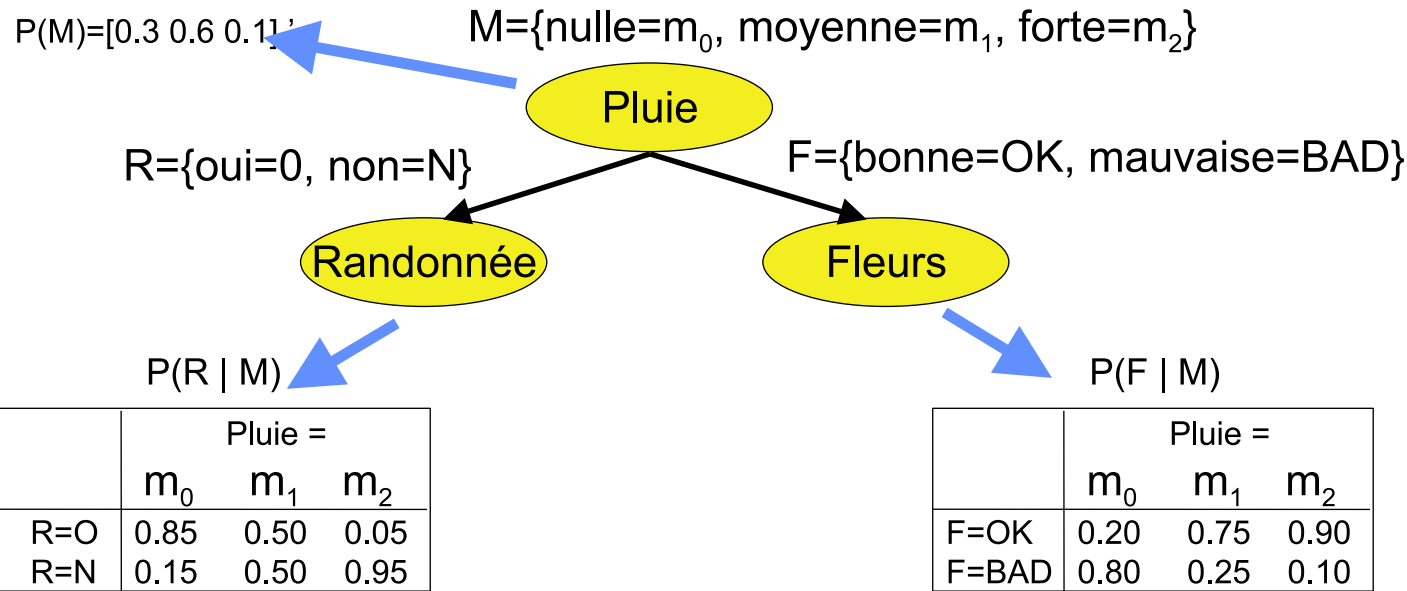
■  $E = \{M = m_2\}$  fin

■ en  $F$  :

- $\pi(F) = P(F|M)\pi_F(M) = [0.9 \ 0.1]$
- $\lambda(F) = [1 \ 1]$  (feuille)
- $P(F|E) \propto \lambda(F)\pi(F) = [0.9 \ 0.1]$

Pluie=Forte  $\Rightarrow$  Fleurs arrosées

# Exemple




- $E = \{F = OK(0.2) | BAD(0.8)\}$  (soft evidence)

En  $F$  :

- $\lambda(F) = \pi(F) = [0.2 \ 0.8]$
- $P(F|E) \propto \lambda(F)\pi(F) = [0.2 \ 0.8]$
- message envoyé au parent :
  - $\lambda_F(M) = \lambda(F)P(F|M) =$   
 $[0.68 \ 0.35 \ 0.26]$

		0.20	0.75	0.90
		0.80	0.25	0.10
0.2	0.8	0.68	0.35	0.26

# Exemple




- $E = \{F = OK(0.2) | BAD(0.8)\}$  (soft evidence)

En  $R$  :

- $\lambda(R) = [1 \ 1]$  (feuille)
- $\pi(R) = ?$
- message envoyé au parent :
  - $\lambda_R(M) = \lambda(R)P(R|M) = [1 \ 1 \ 1]$

# Exemple




- $E = \{F = OK(0.2) | BAD(0.8)\}$  (soft evidence)

En  $M$  :

- $\lambda(M) = \lambda_R(M)\lambda_F(M) = [0.68 \ 0.35 \ 0.26]$
- $\pi(M) = P(M) = [0.3 \ 0.6 \ 0.1]$  (racine)
- $P(M|E) \propto \lambda(M)\pi(M) = [0.463 \ 0.477 \ 0.060]$
- message :  $\pi_R(M) = \pi(M)\lambda_F(M) = [0.204 \ 0.216 \ 0.026]$

# Exemple



- $E = \{F = OK(0.2) | BAD(0.8)\}$  (soft evidence)

Retour en  $R$  :

- $\lambda(R) = [1 \ 1]$  (feuille)
- $\pi(R) = P(R|M)\pi_R(M) = [0.283 \ 0.229]$
- $P(R|E) \propto \lambda(R)\pi(R) = [0.553 \ 0.447]$

Fleurs plutôt en mauvais état  $\Rightarrow$  Randonnée = plutôt oui




# Junction Tree (Jensen 1990)

- Message Passing ne s'applique bien qu'aux arbres
- Besoin d'un algorithme plus général
- Principe
  - Transformer le graphe en un arbre (non orienté)...
  - Arbre = arbre de jonction des cliques maximales du graphe moralisé et triangulé
- Moralisation = marier les parents et "désorienter" le graphe
- Triangulation = éviter les cycles dans le graphe non orienté.

# Junction Tree

- Moralisation : marier les parents de chaque nœud



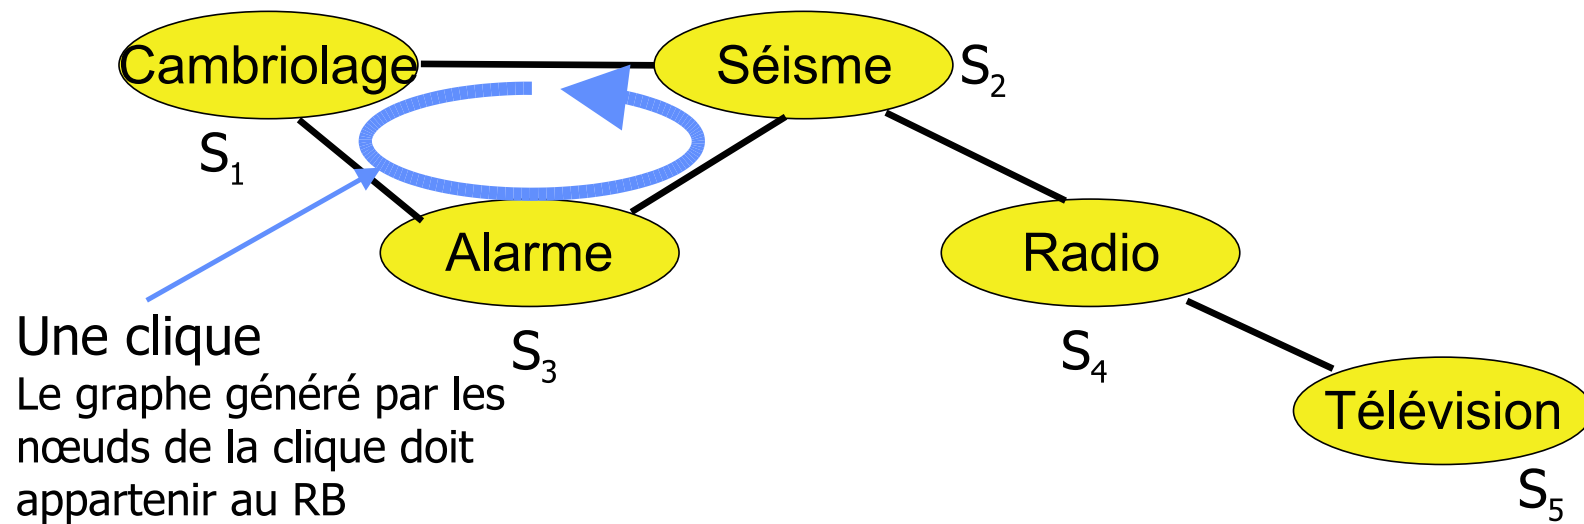


# Junction Tree

- Triangulation : tout cycle de longueur au moins 4 doit contenir une corde (arête reliant deux sommets non consécutifs sur le cycle)
- (= aucun sous-graphe cyclique de longueur  $> 3$ ).
- Triangulation optimale pour des graphes non-dirigés = NP-difficile (comment choisir les meilleures cordes ?)


# Junction Tree

- Clique = sous-graphe du RB dont les nœuds sont complètement connectés
- Clique maximale = l'ajout d'un autre nœud à cette clique ne donne pas une clique



# Junction Tree

- Théorème : Si le graphe est moralisé et triangulé, alors les cliques peuvent être organisées en un arbre de jonction



$$P(S) = \Phi(S1, S2, S3)\Phi(S2, S4)\Phi(S4, S5)$$



# Applications

- Diagnostic et raisonnement dans des systèmes complexes
- Marketing/Finance (modélisation de risques) :
  - ATT : détection de fraudes (mauvais payeurs) pour les factures de téléphone
  - Altaprofit : optimisation de portefeuilles (contrats d'assurance vie)
- Informatique :
  - Microsoft : printer troubleshooting, assistant Office
  - MODIST : évaluation de la qualité pour des développements logiciels





# Applications

## ■ Médecine :

- Aide au diagnostic de problèmes cardio-vasculaires
- Surveillance transfusionnelle, ...

## ■ Industrie :

- NASA : aide au diagnostic de pannes en temps réel pour les systèmes de propulsion de la navette spatiale
- Lockheed Martin : système de contrôle d'un véhicule sous-marin autonome
- Ricoh : aide au télédiagnostic
- EDF : modélisation de groupes électrogènes



# Offre logicielle

## ■ Toolbox

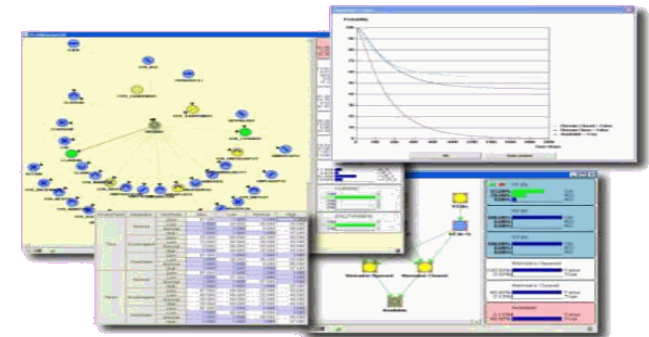
- Bayes Net Toolbox (BNT) pour Matlab
- gR, GRAPPA, ... pour  $\mathcal{R}$
- BNJ, JavaBayes, ... pour Java

## ■ Logiciels non commerciaux

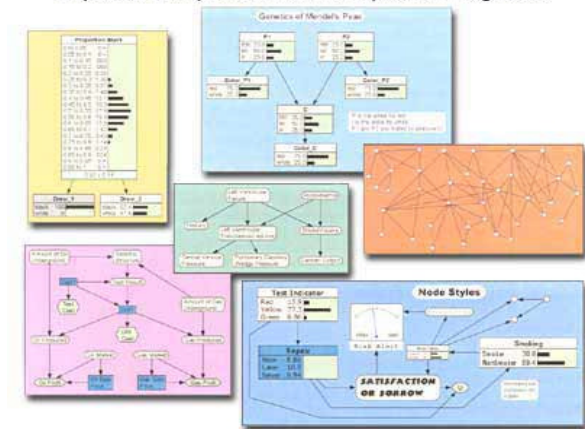
- Microsoft Belief Network [US]
- Genie 2/Smile [US]

## ■ Logiciels commerciaux

- Bayesia [FR]
- ProBT (inférence probabiliste) [FR]
- Hugin [DK]
- Netica [CA]



*A Complete Software Package to Solve Problems Using Bayesian Belief Networks and Influence Diagrams*





# Références



- **Les Réseaux Bayésiens** - P. Naïm, P.H. Willemin, Ph. Leray, O. Pourret, A. Becker (Eyrolles)
- **Probabilistic reasoning in Intelligent Systems : Networks of plausible inference** - J. Pearl (Morgan Kaufman)
- **An introduction to Bayesian Networks** - F. Jensen (Springer Verlag)
- **Probabilistic Networks and Expert Systems** - R.G. Cowell & al. (Springer Verlag)
- **Learning Bayesian Networks** - R. Neapolitan (Prentice Hall)
- **Learning in Graphical Models** - Jordan M.I. ed. (Kluwer)